

社群媒體資料分析實務 HW1

1. 執行環境說明

在 Kaggle 提供的 notebook 上，以 Jupyter 作為執行程式的環境，並以 Python 語言實作。資料集則必須要先上傳到 Kaggle 後，再到 notebook 中選擇要使用的資料集來訓練。

2. 程式架構與演算法流程

1. 資料前處理

首先讀取 `data_train_edge` 中的所有資料並加上正標籤，然後建立一個矩陣用於紀錄點跟點之間是否有連線，如此一來就可以得知有多少正樣本(有連線)與負樣本(沒有連線)。但因為正樣本與負樣本的數量相差太多，會妨礙模型的學習，所以只隨機採樣與正樣本同樣數量的負樣本加上負標籤，最後組成數量四萬左右的訓練集。驗證集則是此功課提供的 `predict` 前 500 個答案，用以作為調整模型的標準。接著使用 Networkx 計算 Jaccard Coefficient、Adamic Adar、Preferential Attachment 等演算法計算點跟點之間的關聯性，加入到訓練及與驗證集中以幫助預測。

2. 使用的演算法

為了進行關聯預測，就需要分析整個網路中每個點與其

他點的關係，首先先計算每個點 v 的鄰居有多少並記錄成 $N(v)$ ，然後再用下列公式去計算點與點之間的關係，以便模型預測。

i. Jaccard Coefficient:

計算兩點共同鄰居後用兩點總共鄰居數量做

Normalize，可用於衡量兩點鄰居的相似度。

$$\frac{|\mathcal{N}(v_i) \cap \mathcal{N}(v_j)|}{|\mathcal{N}(v_i) \cup \mathcal{N}(v_j)|}$$

ii. Adamic Adar:

用兩點共同的鄰居來計算，但是以共同鄰居的鄰居之對數為分母加總起來，目的是給共同鄰居有較多鄰居數量的較少的權重，較少鄰居數量的較大的權重，因為較少鄰居數量的重要性可能比較高。

$$\sum_{v \in \mathcal{N}(v_i) \cap \mathcal{N}(v_j)} \frac{1}{\log |\mathcal{N}(v)|}$$

iii. Preferential Attachment:

因為有越多鄰居的人，就更有可能與其他點有關聯，所以計算兩點個別鄰居數量的乘積作為參數。

$$k_i \cdot k_j = |\mathcal{N}(v_i)| \cdot |\mathcal{N}(v_j)|$$

3. 使用的模型

我使用 XGBClassifier 作為預測模型，再加上使用

GridSearchCV 並根據驗證集來測試各參數搭配的成果，最後選出數個最高的搭配來設定模型參數。

4. 程式流程架構

