

社群媒體資料分析實務 HW1

M11215101 謝尚恆

程式相關說明

1. 讀取訓練集、測試集和提交範例 (sample submission) 的 CSV 文件。
2. 使用 XGBoost 模型進行訓練
定義 `n_estimators=100` (建立 100 棵決策樹)、`max_depth=10` (樹的深度最大為 10)、`learning_rate=0.05` (模型的學習率)
`x_train` 定義為每組 pair 的 node1, node2 編號 (用 `drop()` 將 label 拿掉)
`y_train` 定義為該 pair 是否有相連 (label=0 or 1)
`x_test` 定義為要預測的每組 pair 的 node1, node2 編號 (用 `drop()` 將 idx 拿掉)
因為 kaggle 上的資料集並沒有預測 pair 的實際結果，所以沒有定義 `y_test`。
3. 將預測結果生成的 submission 寫入到 CSV 文件中。
4. `print 'Model training and testing done!'`，表示模型訓練和測試完成。

執行程式的方法：於終端機輸入 `python hw1.py` 即可 輸出為 `submission.csv`

流程圖



心得

一開始我是將資料讀進來然後做簡單的資料前處理後就直接用 XGBoost 模型訓練，結果上傳幾次到 Kaggle 的結果都不是很好 (大約 0.56~0.6 之間)。後來想到可以運用課堂上所學的衡量關聯性方法，試試看能不能提升預測表現，於是我試著先將訓練集的資料做 Preferential Attachment 的運算，並以算出來的關聯性依據去做模型預測，結果上傳到 Kaggle 之後，效果反而比讀進來直接預測還糟糕 (只有 0.52)。後來去研究了才知道 XGBoost 在結構化資料的預測表現比較好，但是對於 graph 類型的資料，不太能夠捕捉其複雜結構和局部依賴關係，所以就算有 Preferential Attachment 做輔助，效果也沒有比較好。