

Q1: 根據上課所介紹的 Rule Evaluation Metrics: Confidence 及 Lift，假設我們定義 Confidence 為在 item A 出現於購物籃的情況下，item B 出現的機率：

$$Conf(A \rightarrow B) = Pr(B|A)$$

(1) Confidence 的其中一項缺點為，它忽略了 B 本身的出現機率 $Pr(B)$ ，試以理論或課堂提及的例子證明為何這在衡量 Association rule 的表現上，會是一項缺點？

(2) 並同時討論 Lift 會不會有這樣的問題。(回答會 or 不會，以及原因)

A:

$$(1) Pr(B|A) = \frac{Pr(A \cap B)}{Pr(A)}$$

，雖然忽略了 $Pr(B)$ ，但是

$Pr(B)$ 會影響到 $Pr(A \cap B)$ 。

假設 $Pr(B)$ 特別高，那麼 A, B 會同時出現在一個 transaction 的機率，也就是 $Pr(A \cap B)$ 也會比較高，進而影響讓

$Conf(A \rightarrow B)$ 變高。不過我們無法說明 confidence 很高是因為 A, B 真的很有關聯，還是單純因為 $Pr(B)$ 特別高。

$$(2) Lift(A \rightarrow B) = \frac{Pr(B|A)}{Pr(B)} = \frac{Conf(A \rightarrow B)}{Pr(B)}$$

不會，因為 Lift 有考量到 B 本身的出現機率 $Pr(B)$ 。

Q2:

$$(1) Lift(A \rightarrow B) = \frac{P(B|A)}{P(B)}$$

，試著基於上述的

confidence 公式解釋 $Lift > 1$ 的意義。

(2) 同時說明在 Lift 等於以及小於 1 在商品銷售解讀上有什麼意義

A:

$$(1) Lift(A \rightarrow B) = \frac{P(B|A)}{P(B)} = \frac{P(A \cap B)}{P(A)P(B)}$$

如果 $Lift > 1$ ，代表 $P(A \cap B) > P(A)P(B)$ ，也就是 A, B 正相關。

(2) $Lift = 1$ ，代表 $P(A \cap B) = P(A)P(B)$ ，也就是 A, B 彼此獨立。

如果 $Lift < 1$ ，代表 $P(A \cap B) < P(A)P(B)$ ，也就是 A, B 負相關。

Q3: 在以 confidence 為 metric 且 min_support 設定為 0.009 的情況下，以 Apriori algorithm 分析作業提供的資料集，前 10 條最佳 rule 中，是否發現「某類型商品」常常伴隨著「某類型商品」出現？

(1) 請列出前10條rule(使用weka的同學請將結果截圖，並另存結果附在壓縮檔內)

(2) 描述你觀察到的商品關聯性分析

A:

(1)

```
Best rules found:
1. POPPYS PLAYHOUSE BATHROOM=True POPPYS PLAYHOUSE KITCHEN=True 95 ==> POPPYS PLAYHOUSE LIVINGROOM =True 91 <conf:(0.96)> Lift:(68.91) Lev:(0.01) [89] conv:(18.74)
2. POPPYS PLAYHOUSE BATHROOM=True POPPYS PLAYHOUSE BEDROOM =True 94 ==> POPPYS PLAYHOUSE LIVINGROOM =True 90 <conf:(0.96)> Lift:(68.88) Lev:(0.01) [88] conv:(18.54)
3. POPPYS PLAYHOUSE BATHROOM=True POPPYS PLAYHOUSE LIVINGROOM =True 96 ==> POPPYS PLAYHOUSE KITCHEN=True 91 <conf:(0.95)> Lift:(54.48) Lev:(0.01) [89] conv:(15.72)
4. POPPYS PLAYHOUSE BATHROOM=True POPPYS PLAYHOUSE LIVINGROOM =True 96 ==> POPPYS PLAYHOUSE BEDROOM =True 90 <conf:(0.94)> Lift:(57.16) Lev:(0.01) [88] conv:(13.49)
5. POPPYS PLAYHOUSE BATHROOM=True 103 ==> POPPYS PLAYHOUSE LIVINGROOM =True 96 <conf:(0.93)> Lift:(67.05) Lev:(0.01) [94] conv:(12.7)
6. CHARLOTTE BAG PINK POLADOT=True STRAWBERRY CHARLOTTE BAG=True 97 ==> RED RETROSPO CHARLOTTE BAG=True 90 <conf:(0.93)> Lift:(31.99) Lev:(0.01) [87] conv:(11.77)
7. POPPYS PLAYHOUSE BATHROOM=True 103 ==> POPPYS PLAYHOUSE KITCHEN=True 95 <conf:(0.92)> Lift:(53.01) Lev:(0.01) [93] conv:(11.25)
8. POPPYS PLAYHOUSE BATHROOM=True 103 ==> POPPYS PLAYHOUSE BEDROOM =True 94 <conf:(0.91)> Lift:(55.65) Lev:(0.01) [92] conv:(10.13)
9. POPPYS PLAYHOUSE BEDROOM =True POPPYS PLAYHOUSE LIVINGROOM =True 122 ==> POPPYS PLAYHOUSE KITCHEN=True 111 <conf:(0.91)> Lift:(52.29) Lev:(0.01) [108] conv:(9.99)
10. POPPYS PLAYHOUSE LIVINGROOM =True 139 ==> POPPYS PLAYHOUSE KITCHEN=True 126 <conf:(0.91)> Lift:(52.1) Lev:(0.01) [123] conv:(9.76)
```

(2)

Q4: 在 confidence 設為最低的情況下（即為0%），將 min_support 設定大於等於多少，剛好令 Apriori algorithm 找不出任何 rule？而這個門檻的 min_support 值代表什麼意義？（精確到小數第4位即可）

A:0.0256

- 代表沒有任何一組itemset在這10000筆transaction中同時出現在256筆或以上

Q5: 試著找出一組 item quadruple (W, X, Y, Z)，此組合在資料集出現的 support 數量至少為 80 筆，符合此定義的組合中，confidence 最高的 rule 為何？

A: POPPYS PLAYHOUSE BATHROOM=True POPPYS PLAYHOUSE BEDROOM =True POPPYS PLAYHOUSE KITCHEN=True 87 ==> POPPYS PLAYHOUSE LIVINGROOM =True 85

其confidence = 0.98

Q6: 試著調整 support 及更改 metric，找出跟 Q3 結果較不一樣的 rules。請解釋你為何挑選這個 metric，與先前找到的 rules 有什麼差異？並列出前十名的 rules。

A: 因為Lift這個指標可以用來表示這些attribute之間的相關關係，所以我想透過這個指標找到最正相關的前10條規則。

```
1. POPPYS PLAYHOUSE BEDROOM =True POPPYS PLAYHOUSE LIVINGROOM =True 122 ==> POPPYS PLAYHOUSE BATHROOM=True 90 conf:(0.74) < Lift:(71.62)> Lev:(0.01) [88] conv:(3.66)
2. POPPYS PLAYHOUSE BATHROOM=True 103 ==> POPPYS PLAYHOUSE BEDROOM =True POPPYS PLAYHOUSE LIVINGROOM =True 90 conf:(0.87) < Lift:(71.62)> Lev:(0.01) [88] conv:(7.27)
3. POPPYS PLAYHOUSE BATHROOM=True 103 ==> POPPYS PLAYHOUSE KITCHEN=True POPPYS PLAYHOUSE LIVINGROOM =True 91 conf:(0.88) < Lift:(70.12)> Lev:(0.01) [89] conv:(7.82)
4. POPPYS PLAYHOUSE KITCHEN=True POPPYS PLAYHOUSE LIVINGROOM =True 126 ==> POPPYS PLAYHOUSE BATHROOM=True 91 conf:(0.72) < Lift:(70.12)> Lev:(0.01) [89] conv:(3.46)
5. POPPYS PLAYHOUSE LIVINGROOM =True 139 ==> POPPYS PLAYHOUSE BATHROOM=True POPPYS PLAYHOUSE KITCHEN=True 91 conf:(0.65) < Lift:(68.91)> Lev:(0.01) [89] conv:(2.81)
6. POPPYS PLAYHOUSE BATHROOM=True POPPYS PLAYHOUSE KITCHEN=True 95 ==> POPPYS PLAYHOUSE LIVINGROOM =True 91 conf:(0.96) < Lift:(68.91)> Lev:(0.01) [89] conv:(18.74)
7. POPPYS PLAYHOUSE BATHROOM=True POPPYS PLAYHOUSE BEDROOM =True 94 ==> POPPYS PLAYHOUSE LIVINGROOM =True 90 conf:(0.96) < Lift:(68.88)> Lev:(0.01) [88] conv:(18.54)
8. POPPYS PLAYHOUSE LIVINGROOM =True 139 ==> POPPYS PLAYHOUSE BATHROOM=True POPPYS PLAYHOUSE BEDROOM =True 90 conf:(0.65) < Lift:(68.88)> Lev:(0.01) [88] conv:(2.75)
9. POPPYS PLAYHOUSE BATHROOM=True 103 ==> POPPYS PLAYHOUSE LIVINGROOM =True 96 conf:(0.93) < Lift:(67.05)> Lev:(0.01) [94] conv:(12.7)
10. POPPYS PLAYHOUSE LIVINGROOM =True 139 ==> POPPYS PLAYHOUSE BATHROOM=True 96 conf:(0.69) < Lift:(67.05)> Lev:(0.01) [94] conv:(3.13)
```

Q7: 簡單描述實作本次作業的過程。(用什麼工具執行演算法，參數如何設定，做了哪些前處理...等)

A:

前處理

- 寫了一隻python程式將儲存格中的FALSE都改成?
- 移除了在標題列中所有的撇號

演算法執行(使用WeKa)

- 輸入前處理後的csv檔
- 先按照Q3的要求調整參數
- 在Q4中先將confidence門檻設成0執行一遍，根據結果調整min_support為0.0256，再執行一次就沒有任何rule能過這個門檻了。
- 在做Q5時，confidence門檻先維持0，調整min_support為0.008、輸出的Best rule為20條。
- 做Q6時，我基於Q3的要求，改變metricType，從confidence改成lift。