

Classification

M11215101 謝尚恆

使用的工具為 weka

這次使用的演算法為 Random Forest

Random Forest 其實就是由很多棵 decision tree 所組成，使用 Bagging 加上隨機特徵採樣的方法所產生出來的整體學習演算法。因為 decision tree 太複雜的話很容易 overfitting，因此 Random Forest 藉由多棵不同樹的概念所組成以避免 overfitting，並使得預測能力更提升。

Random Forest 的流程如下：

1. 從訓練集中抽取 n 筆資料出來
2. n 筆資料隨機挑選 k 個特徵做 sample
3. 重複 m 次，產生 m 棵決策樹
4. 多數投票機制進行預測，也就是若運算結果為 class p 的 decision tree 最多，則某筆資料為 class p 。

實作步驟：

1. 將 training data 匯入 weka，使用 NumericToNominal 這個 filter，並把 attributeIndices 改成 last。把最後一個 class 的 type 從 Numeric 改成 Nominal。
2. Classifier 套用的是 tree-based 演算法 RandomForest，先用 Test options 選擇 percentage split 並設定 90%來訓練 training data。
3. 然後 Test options 選擇 supplied test set 並匯入 testing data，將結果 output 成 result.csv。
4. 因為 RandomForest 的預測結果其顯示格式為時間(h:mm)，然後預測出來的 class 是放在分鐘那邊，所以我使用 `right(text(c2,"h:mm"))`先將 mm 提取出來，然後再建立一個新的 csv 檔 M11215101_謝尚恆.csv，將提取出來的 class 放入。

調整哪些參數來優化你的模型？調整了 numIterations，也就是 decision tree 的數量。預設是 100，有試著調整讓 tree 的數量更多，不過結果卻沒什麼影響。

使用什麼方式進行 validation 以避免 overfitting？將 training data 的 10%當作是 validation set