

Data Mining Homework 2

Due: 2023/11/16

Clustering: K-means

Dataset description:

of data: 2000

of attribute: 9

of cluster: 6

公式一、 cost of clustering using Euclidean distance

$$\phi = \sum_{x \in \mathcal{X}} \min_{c \in \mathcal{C}} \|x - c\|^2$$

公式二、 cost of clustering using Manhattan distance

$$\psi = \sum_{x \in \mathcal{X}} \min_{c \in \mathcal{C}} |x - c|$$

這次作業統一使用 weka 操作，請於報告附上各題要求實作的截圖，並提供能夠再現你結果的必要資訊(例如: 如何調整參數、用什麼工具繪製圖表等等)

(a) 請使用上課所教的 Euclidean distance 作為計算資料點間相似度的依據，並探討以下兩種 centroid initialization 的方法，分別執行 Simple K means 演算法。

1. 以 weka 作為分析工具，請設定 initialization method 為 “random”，並把 seed 參數調整為: 456，然後對作業提供的資料集，執行 k-means 分群演算法，並記錄下第1到第15個 iteration 所得到的 Within cluster sum of squared error (SSE)(公式一)。
 - 請將得到的結果，記錄在 excel，並繪製成 x-y 折線圖，x 軸標記由 1 開始的 iteration 數量，y 軸為該 iteration 得到的 SSE。
2. 同上題的題目要求，但改用 “farthest first” 為 initialization method，並一樣使用 456 作為 seed。
 - 請將本題得到的 iteration-error 折線圖，繪製到和上題同一個圖中，並在圖例上標記清楚，兩條折線圖各自的名稱 (Euclidean-random / Euclidean-farthest)。
3. 記錄 Euclidean distance 搭配 random initialization 以及 Euclidean distance 搭配 farthest initialization 這兩種方式做幾次 iteration 後，SSE 會收斂？請回答，並截圖記錄。
4. 請分別對兩種情況下的分群結果，以 多至少 的方式，列出當演算法停止時，最終 cluster 包含的資料點數量，請回答，並截圖記錄。

舉例：

Euclidean-random: 150, 120, 100, 90, 80, 60

Euclidean-farthest: 180, 140, 100, 100, 40, 40

(b) 請使用上課所教的 Manhattan distance 作為計算資料點間相似度的依據，並探討以下兩種 centroid initialization 的方法，分別執行 Simple K means 演算法。

1. 以weka 作為分析工具，請設定 initialization method 為 “random”，並把 seed 參數調整為: 456，然後對作業提供的資料集，執行 k-means 分群演算法，並記錄下第1到第15個iteration所得到的 Sum of within cluster distances(公式二)
 - 請將得到的結果，記錄在excel，並繪製成x-y 折線圖，x 軸標記由1開始的iteration 數量，y 軸為該 iteration 得到的 Sum of within cluster distances。
2. 同上題的題目要求，但改用 “farthest first” 為initialization method，並一樣使用 456 作為 seed。
 - 請將本題得到的iteration-error 折線圖，繪製到和上題同一個圖中，並在圖例上標記清楚，兩條折線圖各自的名稱 (Manhattan-random / Manhattan-farthest)。
3. 記錄**Manhattan distance**搭配**random initialization** 以及 **Manhattan distance**搭配 **farthest initialization**這兩種方式做幾次iteration後，Sum of within cluster distances會收斂？請回答，並截圖記錄。
4. 請分別對兩種情況下的分群結果，以多至少的方式，列出當演算法停止時，最終 cluster包含的資料點數量。請回答，並截圖記錄。

舉例來說:

Manhattan-random: **150, 120, 100, 90, 80, 60**

Manhattan-farthest: **180, 140, 100, 100, 40, 40**

(c) 試比較 (a) 和 (b) 的結果，有沒有觀察到什麼值得討論的現象?並請根據學習到的 k-means 知識，試著解釋你的發現。

(d) 請繪製出 number of clusters(k)-to-SSE 的折線圖。實驗條件為: 以 Euclidean distance 為 similarity function、初始 centroids 採用 random initialization、maximum iteration 數量設為 25。探討number of clusters (k)，從1,2,3...依序漸增到12 時，相對應的 Within cluster sum of squared errors 分別為多少。

(e) 根據 (d) 的結果，是否我們會傾向使用越大的 cluster 數量來跑 k-means 分析我們的資料集會越好?請說明你回答yes or no 的理由。

(f) 請嘗試使用 [UCI Repository](#) 中或自己找的資料集，用你學到的方法把資料分群。簡單說明你的資料集。用Weka或是其他工具，展示一張分群結果可視化圖示。

Multi-class classification

Dataset description:

of Training data : 718

of Testing data: 180

of Attribute: 34

of class : 7

Rules:

限使用 **Tree-based** 分類演算法，可以上課提過或是投影片有列出的方法為主。

可以對 Data 作任何你覺得能增進效能的前處理，並請在報告中討論原因。

請在 Kaggle 平台上，上傳你對 testing dataset 的預測結果，上傳格式請參考 prediction_sample.csv，public 與 private 的比例為 60% 比 40%。

Hint: 避免 classifier overfitting。

Public Baseline accuracy: 0.83333

結果超過 baseline(private) 可以拿到基本分，其餘根據報告內容評分

<https://www.kaggle.com/t/ccb27a42275f4e359b9287ffeb39afeb>

每日上傳次數限制: 3 次。

名稱請用學號_姓名。

● 繳交項目

1. Clustering 報告 (pdf)
2. Classification 報告(pdf)，開頭請先列出你是用什麼 Tool 完成，並簡介你所使用的演算法工作原理，需要調整哪些參數來優化你的模型?以及使用什麼方式進行 validation 以避免 overfitting?

最後所有項目包裝成壓縮檔上傳 moodle，檔名為學號+_DM_HW2

EX: M12345678_DM_HW2